Mini Projet

Deep Learning

Réseaux de neurones convolutionnels (CNN)

4DS

L'objectif de ce mini projet est de se familiariser avec les réseaux de neurones convolutionnels, très adaptés aux images. Pour se faire, nous étudierons les couches classiques de ce type de réseaux et nous mettrons en place un premier réseau appris sur le jeu de données standard CIFAR-10. Une fois le premier réseau testé, nous aborderons différentes techniques permettant d'améliorer le processus d'apprentissage du réseau : normalisation, data augmentation, dropout et batch normalization.

1 Partie 1:Introduction aux réseaux convolutionnels

Les réseaux de neurones convolutionnels (CNN) sont devenus les architectures état-de-l'art dans la quasi-totalité des tâches de machine learning appliquées aux images. Ces réseaux diffèrent des réseaux plus classiques par les couches de base utilisées dans leur architecture. On y retrouve souvent deux types de couches différents : la convolution et le pooling.

1.1 Les couches de convolution

Entrée:
Ces couches prennent en entrée un ensemble de D feature maps (c'est-à-dire un tenseur soit l'équivalent en 3 dimensions d'une matrice), chaque feature map étant une matrice de taille $n_x \times n_y$. On a donc une entrée de taille $n_x \times n_y \times D$.
Sortie:
Sur cette entrée, on applique C convolutions, chacune avec un filtre de convolution de taille $w \times h \times D$, on a généralement $w = h = k$ qu'on appelle taille du kernel. Ce sont ces C filtres qui constituent les paramètres que l'on va apprendre. Chaque convolution avec un filtre produit une feature map de sortie, on a donc en sortie un ensemble de feature maps de taille $n'_x \times n'_y \times C$, où n'_x et n'_y dépendent de la façon dont on réalise la convolution.
Hyperparamètres
En plus du nombre de filtres et de la taille du kernel, il y a deux hyperparmètres courants pour la convolution, le padding et le stride. Le padding indique combien de rangées de 0 on ajoute autour de l'entrée. Le stride indique de combien de pas on se déplace entre deux calculs de la convolution. La convolution **classique** a une sortie plus petite que l'entrée à cause de la taille du filtre que l'on

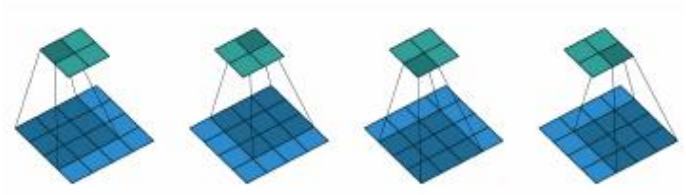

(a) Convolution simple, pas de padding, stride de 1, kernel de taille 3.

doit placer à l'intérieur de la feature map d'entrée, voir figure . Ajouter du padding permet par exemple de retrouver la taille initiale, voir figure . Ajouter un stride permet de sauter des valeurs, cela correspond à faire du sous-échantillonnage de la sortie, voir figure.

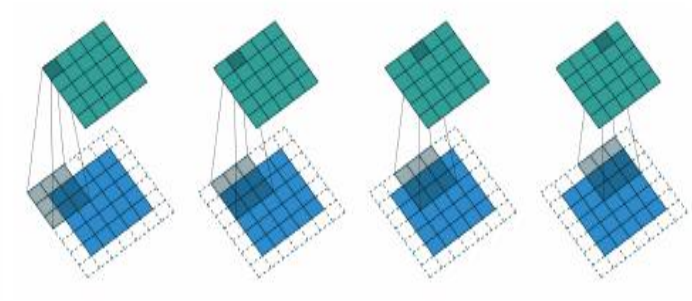

: (b) Convolution avec padding de 1, stride de 1, kernel de taille 3.

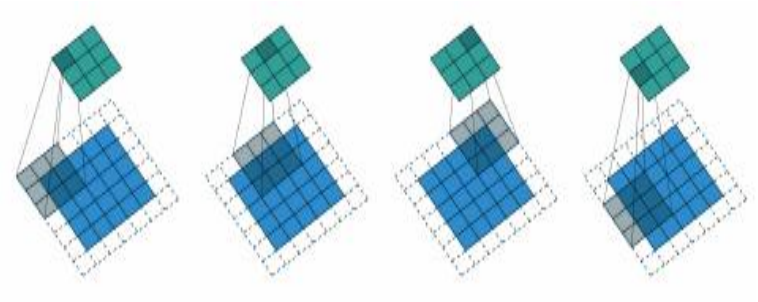

(d) Convolution avec padding de 1, stride de 2, kernel de taille 3.

1.2 Couches de pooling

Principe:

Le pooling est une fonction de sous-échantillonnage spatial. Elle prend toujours en entrée des feature maps de taille $n_x \times n_y \times D$, et réduit les deux premières dimensions spatiales. Le calcul s'effectue selon le même principe qu'une convolution, mais s'applique sur chaque feature map indépendamment. On parcourt donc chaque feature map avec une fenêtre glissante, mais au lieu de réaliser un produit de convolution entre la fenêtre et un filtre, on réalise une opération de pooling sur la fenêtre d'entrée pour produire une valeur. On obtient donc une sortie de taille $n'_x \times n'_y D$ avec n'_x et n'_y significativement plus petits que n_x et n_y (souvent d'un facteur 2).

Hyperparamètres

Une couche de pooling a une taille de kernel (définissant la taille de la fenêtre), un stride et du padding qui se comportent comme pour la convolution, et une opération de pooling, les plus courantes étant le max pooling (on garde la valeur maximale dans la fenêtre) et l'average pooling (on prend la valeur moyenne de la fenêtre). Un pooling très courant est un max pooling avec kernel de taille 2, stride de taille 2 et sans padding, comme présenté la figure suivante:

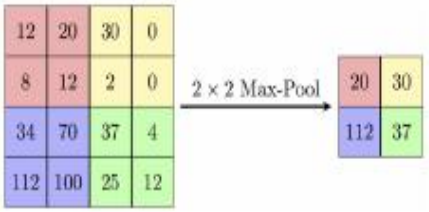

(c) Exemple de max pooling, pas de padding, stride de 2, kernel de taille 2.

1.3 Architectures convolutionnelles courantes

Les réseaux de neurones convolutionnels classiques sont généralement composés d'une succession de couches de convolutions (avec $ReLU$) avec de plus en plus de filtres, et dont la dimension spatiale est progressivement réduite par des couches de max pooling possiblement jusqu'à aggregation totale des dimensions spatiales, il ne reste donc plus que la "profondeur" correspondant au nombre de filtres appliqués par la dernière convolution ($1 \times 1 \times C$). On y ajoute enfin généralement une ou quelques couches linéaires (appelées fully-connected). Un exemple de ce type d'architecture est le réseau VGG16 (Simonyan et Zisserman) (2014). Depuis, des architectures plus complexes se sont développées, notamment les architectures Inception ou ResNet, et leurs dérivés et combinaisons.

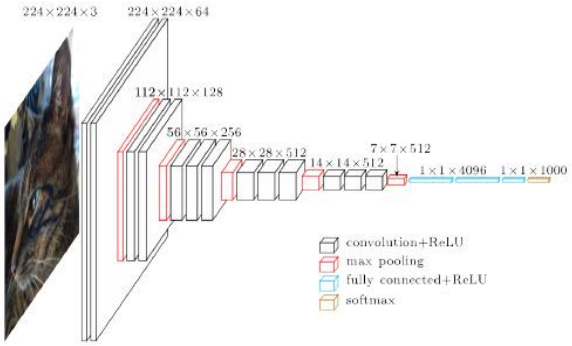

1.4 Questions

1. Considérant un seul filtre de convolution de padding p, de stride s et de taille de kernel k, pour une entrée de taille $x \times y \times z$ quelle sera la taille de sortie ?
   (a) Combien y a-t-il de poids à apprendre ?
   (b) Combien de poids aurait-il fallu apprendre si une couche fully-connected devait produire une sortie de la même taille ?

2. Quels avantages apporte la convolution par rapport à des couches fully-connected ? Quelle est sa limite principale ?

3. Quel interêt voyez-vous à l'usage du pooling spatial ?

4. Supposons qu'on essaye de calculer la sortie d'un réseau convolutionnel classique (par exemple celui VGG16) pour une image d'entrée plus grande que la taille initialement prévue (224×224 dans l'exemple). Peut-on sans modifier l'image calculer tout ou une partie des couches du réseau ?

5. Montrer que l'on peut voir les couches fully-connected comme des convolutions particulières.

6. Supposons que l'on remplace donc les fully-connected par leur équivalent en convolutions, répondre à nouveau à la question 4. Si on peut calculer la sortie, quelle est sa forme et son intérêt ?

7. On appelle champ récepteur (receptive field) d'un neurone l'ensemble des pixels de l'image dont la sortie de ce neurone dépend. Quelles sont les tailles des receptive fields des neurones de la première et de la deuxième couche de convolution ? Pouvez-vous imaginer ce quâil se passe pour les couches plus profondes ? Comment lâinterpréter ?

2 Partie 2: Apprentissage from scratch du modèle

Nous allons désormais implémenter notre premier réseau convolutionnel que nous allons appliquer à la base de données CIFAR-10. Cette base d'images RGB de 32×32 pixels comporte 10 classes, $50k$ images en train et $10k$ images en test.

2.1 Architecture du réseau

Le réseau que nous allons implémenter a un style proche de l'architecture AlexNet (2012) adaptée à la base CIFAR-10 dont les images sont plus petites. Il sera composé des couches suivantes :

- conv1 : 32 convolutions 5×5, suivie de $ReLU$
- pool1 : max-pooling 2×2
- conv2 : 64 convolutions 5×5, suivie de $ReLU$
- pool2 :max-pooling 2×2
- conv3 : 64 convolutions 5×5, suivie de $ReLU$
- pool3 :max-pooling 2×2
- fc4 : fully-connected, 1000 neurones en sortie, suivie de $ReLU$
- fc5 : fully-connected, 10 neurones en sortie, suivie de $softmax$

2.2 Questions

1. Pour les convolutions, on veut conserver en sortie les mêmes dimensions spatiales qu'en entrée. Quelles valeurs de padding et de stride va-t-on choisir ?
2. Pour les max poolings, on veut réduire les dimensions spatiales d'un facteur 2. Quelles valeurs de padding et de stride va-t-on choisir ?
3. Pour chaque couche, indiquer la taille de sortie et le nombre de poids à apprendre. Commentez cette répartition.
4. Quel est donc le nombre total de poids à apprendre ? Comparer cela au nombre d'exemples.
5. Implémenter l'architecture demandée ci-dessus. Attention à bien faire suffisament d'epoques pour que le modèle ait fini de converger.
6. Entrainer le réseau et tester sur la base de données CIFAR-10.
7. Quels sont les effets du pas d'apprentissage (learning rate) et de la taille de mini-batch ?
8. A quoi correspond l'erreur au début de la première époque ? Comment s'interprète-t-elle ?
9. Interpréter les résultats. Qu'est-ce qui ne va pas ? Quel est ce phénomène ?

3 Partie 3: Améliorations des résultats

3.1 Normalisation des exemples

Une technique courante en machine learning est de normaliser les exemples afin de mieux conditionner l'apprentissage. En apprentissage de CNN, la technique la plus courante est de calculer sur l'ensemble de train la valeur moyenne et l'écart type de chaque channel RGB. On obtient donc 6 valeurs. On normalise ensuite chaque image en soustrayant à chaque pixel la valeur moyenne correspondant à son channel et en le divant par l'écart type correspondant.

3.1.1 Questions

1. Décrire vos résultats expérimentaux.
2. Pourquoi ne calculer l'image moyenne que sur les exemples d'apprentissage et normaliser les exemples de validation avec la même image ?
3. Il existe d'autres schémas de normalisation qui peuvent être plus efficaces. Essayer d'autres méthodes, expliquer les différences et comparer les à celle demandée.

3.2 Augmentation du nombre d'exemples d'apprentissage par data augmentation

Les réseaux de convolutions contiennent souvent plusieurs millions de paramètres et sont appris sur de très grosses bases d'images. CIFAR-10 est un ensemble d'images relativement petit par rapport au nombre de paramètres du modèle. Pour contrer ce problème, on utilise des méthodes de data augmentation qui cherchent à artificiellement augmenter le nombre d'exemples disponibles,

ce qui peut être crucial quand l'ensemble d'apprentissage est petit. Le principe consiste à générer à chaque epoch une "variante" de chaque image, en lui appliquant des transformations aléatoires. Ici, on propose de tester deux transformations les plus courantes : un crop aléatoire de taille 28×28 pixels (parmi les 32×32) et une symétrie horizontale aléatoire de l'image (1 chance sur 2 de l'appliquer). Notons que ces transformations sont appliquées à l'ensemble de train, mais il faut parfois ajuster la phase d'évaluation pour en tenir compte. Par exemple ici, on a réduit la taille de nos images d'apprentissage. On pourrait penser à plusieurs stratégies pour contrer cela, en particulier : modifier le modèle pour prendre des images plus petites et faire un crop centré sur les images de test ou ajouter du padding autour des images de train pour revenir à une taille 32×32. Pour conserver le même nombre de paramètres dans le modèle (afin que nos résultats soient plus facilement comparables), on propose de modifier la couche $pool3$ en ajoutant l'option $ceil\_mode = True$ pour que la taille spatiale de sortie soit toujours 4×4.

3.2.1 Questions

1. Modifier l'appel à datasets.CIFAR10 pour ajouter en train un crop aléatoire taille 28 et une symétrie horizontale aléatoire ; et en test un crop centré taille 28.
2. Modifier la couche $pool3$ pour ajouter l'option $ceil\_mode = True$.
3. Décrire vos résultats expérimentaux et les comparer aux résultats précédents.
4. Est-ce que cette approche par symétrie horizontale vous semble utilisable sur tout type d'images ? Dans quels cas peut-elle l'être ou ne pas l'être ?
5. Quelles limites voyez-vous à ce type de data augmentation par transformation du dataset ?
6. D'autres méthodes de data augmentation sont possibles. Chercher lesquelles et en tester certaines.

3.3 Régularisation du réseau par dropout

On a vu que la couche $fc4$ du réseau contient un très grand nombre de poids, le risque de sur-apprentissage dans cette couche est donc important. Pour remédier à ce problème, nous allons ajouter une couche permettant une régularisation très efficace pour les réseaux de neurones : la couche de dropout. Le principe général de cette couche est de désactiver aléatoirement à chaque passe une partie des neurones du réseau pour diminuer artificiellement le nombre de paramètres.

3.3.1 Questions

1. Ajouter une couche de dropout entre $fc4$ et $fc5$.
2. Décrire vos résultats expérimentaux et les comparer aux résultats précédents.
3. Qu'est-ce que la régularisation de manière générale ?
4. Cherchez et discutez des possibles inteprétations de l'effet du dropout sur le comportement d'un réseau l'utilisant ?
5. Quelle est l'influence de l'hyper-paramètre de cette couche ?
6. Quelle est la différence de comportement de la couche de dropout entre l'apprentissage et l'évaluation ?

3.4 Utilisation de batch normalization

Une dernière statégie d'apprentissage que nous allons tester est la batch normalization. Il s'agit d'une couche qui apprend à renormaliser les sorties de la couche précédente, permettant de stabiliser l'apprentissage.

3.5 Question

1. Ajouter une couche de batch normalization 2D immédiatement après chaque couche de convolution.

2. Décrire vos résultats expérimentaux et les comparer aux résultats précédents.